Elisabeth Weise
R kurs, april 2026

Syfte

Ett försäkringsbolag vill bättre förstå vilka faktorer som driver försäkringskostnader och om prissättningen följer rimliga mönster. Målet med denna analys är att identifiera de viktigaste kostnadsdrivande variablerna och undersöka om en regressionsmodell kan användas som stöd vid framtida prissättning.

Metod

Analysen görs i R och bygger på historiska kunddata (1100 rader) med information om livsstil, hälsa, ålder, kön, sjukdomshistorik, mm. Jag hittade saknade värden på excercise_level, bmi och annual_checkups.

För saknade värden i BMI och annual_checkups har jag tagit medlvärdet för kvinnor och män respektive och imputerar dessa, medan för kategoriska variablen excercise_level, valde jag att ta bort de 22 raderna med saknade värden. Alternativet hade varit att hitta de vanligaste nivåerna för träningsnivå och använda dem för att fylla i saknade värden men det kändes som ett överkomplicerat sätt att hantera ganska lite data.

Jag skapade nya variabler för åldersgrupp, BMI-kategori och ett viktat riskindex (där historiska utbetalningar väger dubbelt så mycket som olyckshistoriken). Syftet med dess variabler var att hitta sätt att förenkla analysen kring vad det är som påverkar försäkringskostnader.

Den beskrivande analysen genomfördes med visualiseringar och statistiska sammanfattningar, följt av en multipel regressionsanalys med tre modellvarianter.

Resultat

Jag började med att titta på fördelningen av försäkringskostnader och ser att det finns en snedfördelning åt höger med outliers vilket drar upp medelvärdet (mean), jämfört med medianen. Vi kommer att se dessa högre outliers från olika vinklar genom analysen.

Av de variabler vi har tillgång till, började jag med att titta på **rökning**, vilket intuitivt skulle vara en faktor som skulle kunna driva upp kostnaden per försäkringstagare. Det jag såg var att gruppen rökare har högre försäkringskostnader än icke-rökare, med en dubbelt så hög mediankostnad för rökare än för icke-rökare.

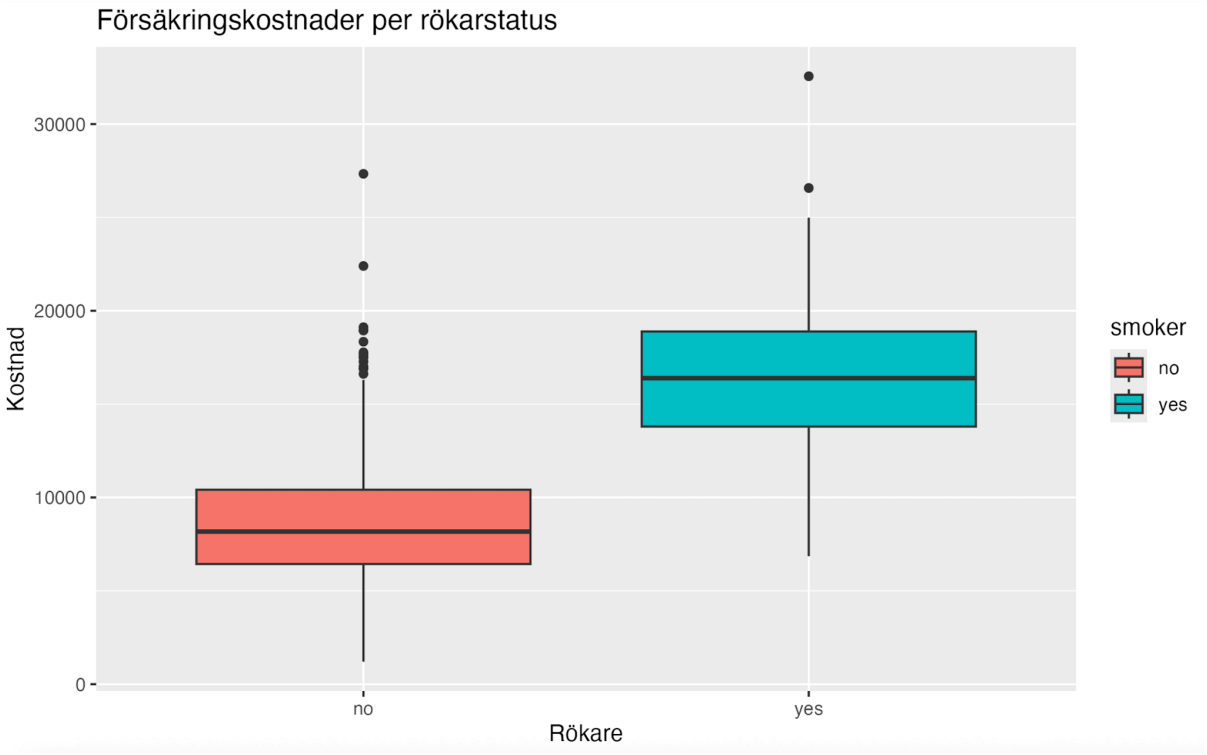

Jag gick sen vidare för att kika på **kronisk sjukdom**. Där kunde jag se att gruppen kroniskt sjuka har högre kostnader än de utan kronisk sjukdom, med en mediankostnaden på cirka 50% högre för kroniskt sjuka än för icke kroniskt sjuka.

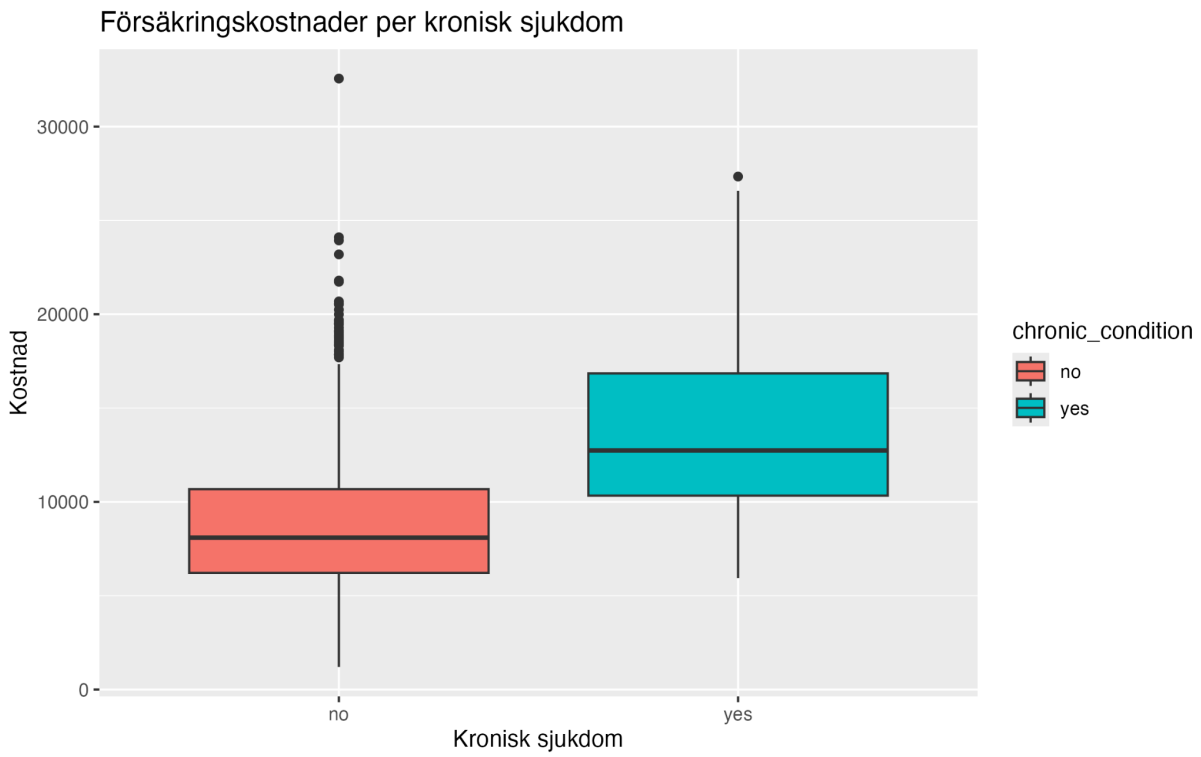

Jag tittade vidare på **BMI** utifrån den de grupperingar jag skapat (baserat på Folkhälsoinstitutets grupperingar) men kopplingen var svagare än vad jagsåg mellan

kostnader och rökning, och kostnader och kronisk sjukdom. Det finns även en inbyggt bias i det sätt som BMI beräknas, då den är byggd på en stereotyp av smala personer. (Kvinnor som tex är vältränade med mycket muskelmassa kommer att ha ett högre BMI än en person med mindre muskelmassa. Det är därför inte en tydlig indikation på hur hälsosam en person är. Dessutom mäts män och kvinnor mot samma BMI skala även om kroppsammanställningen ofta skiljer sig åt mellan könen.) Jag har därför valt att inte gå vidare med denna variabel.

Därefter tittade jag på **ålder**. Här provade jag både att använda vår egen skapade gruppering, samt att se på ålder som en kontinuerlig variabel. Relationen till försäkringskostnader blev tydligast när jag tittade på kostnader som en kontinuerlig variabel, så det är den variabeln jag kommer att gå vidare med. På grafen blir även de högre kostands outliers tydliga.

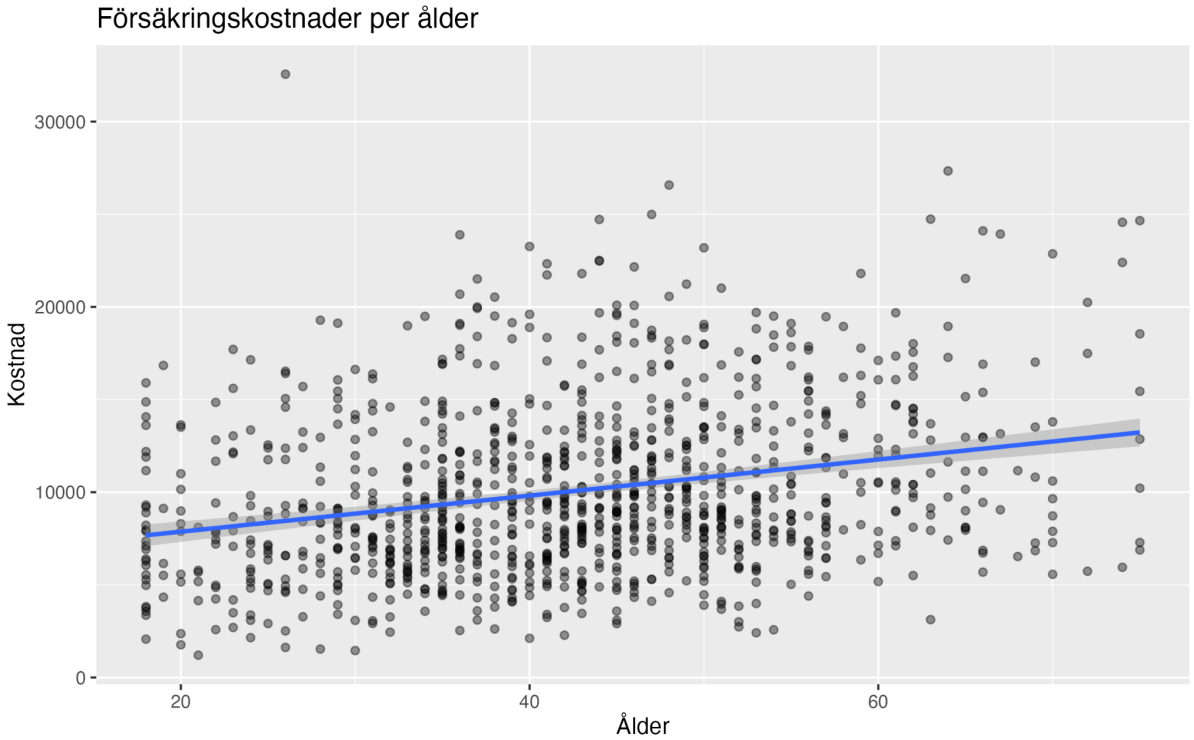

Jag tittade även på det **riskindex** jag skapat, som var viktat mellan tidigare olyckor och tidigare försäkringsutbetalningar. Dock reflekterade jag över att prior_claims måste vara kopplat till charges, och att det därför finns en inbyggd korrelation mellan dessa två variabler. Jag valde därför att gå vidare med **tidigare rapporterade olyckor,** snarare än ett riskindex som innehöll tidigare försäkringsutbetalningar, och fann en tydlig korrelation mellan tidigare olyckor och försäkringskostnader.

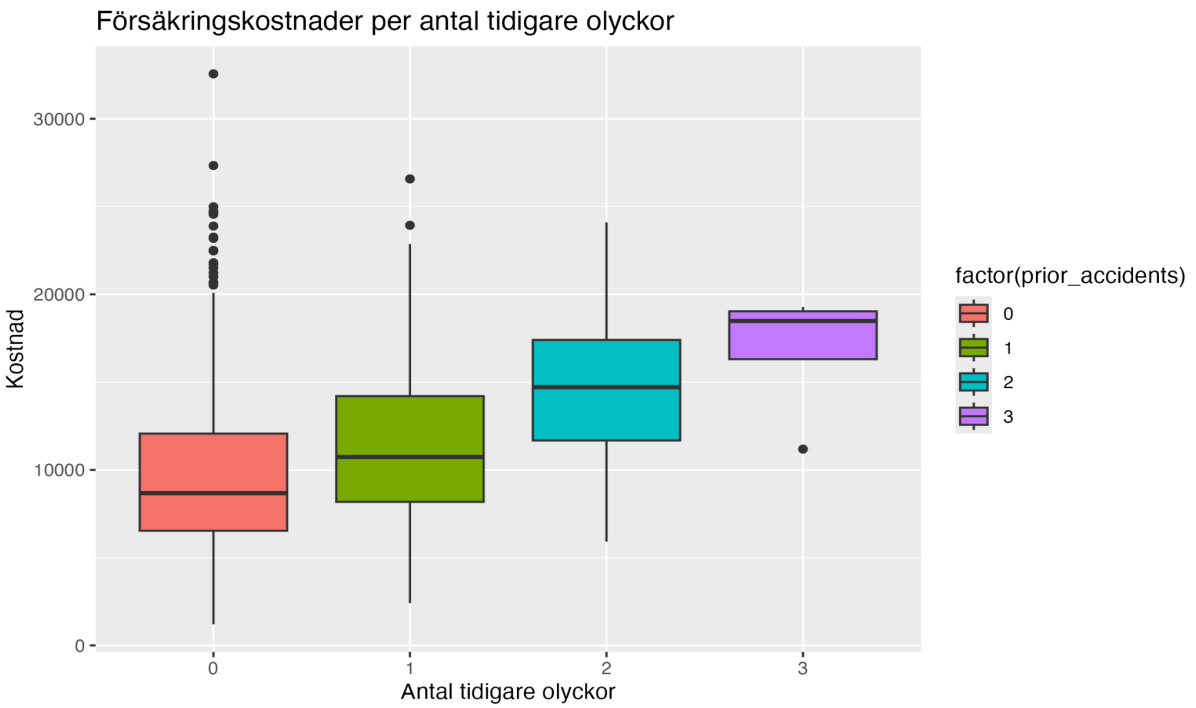

Slutligen analyserade jag även om försäkringstagare med barn hade högre eller lägre försäkringskostnad. Och även om jag kunde se något högre kostnader för försäkringstagare med barn, så var det inte lika tydligt som de andra variablerna som analyserats.

Regressionsanalys

Utifrån vår dataanalys valde jag att gå vidare med multipel regressionsmodell, där jag undersöker sambandet mellan en kontinuerlig målvariabel (charges) och flera förklarande variabler: rökning, kronisk sjukdom, ålder och tidigare olyckor. Variablerna valdes eftersom det var de som jag tyckte var mest intressanta efter vår analys. En linjär regressionsmodell är relativt enkel, den undersöker bara linjära samband medan samspelet mellan olika variabler kan vara mer komplext. Men dess enkelhet kan även vara en styrka i det att den är lätt att utvärdera och förstå.

model 1				
	Estimate	Std. Error	t value	Pr(>|t|)
(Intercept)	4,303	283.86	15.158	< 2e-16 ***
smokeryes	7,482	203.37	36.792	< 2e-16 ***
chronic_condition yes	4,088	185.28	22.065	< 2e-16 ***
age	72	6.45	11.196	< 2e-16 ***
prior_accidents	1,267	158.73	7.982	3.69e-15 ***
Residual standard error: 2585 on 1073 degrees of freedom				
Multiple R-squared: 0.6839,				
Adjusted R-squared: 0.6828				
F-statistic: 580.5 on 4 and 1073 DF, p-value: < 2.2e-16				

Modell 1 förklarar 68% av variationerna i kostnader. Varje variabels bidrag utvärderades med ett t-test, där p-värdet anger sannolikheten att sambandet beror på slumpen. Alla variabler i modell 1 har p-värden under 0.05, vilket innebär att vi med god säkerhet kan säga att de har ett verkligt samband med kostnader. Kostnaden för rökare är i genomsnitt 7,482 kr högre än för en icke-rökare. För de med kroniska sjukdomar ligger kostnaden 4,088 kr högre än för de utan sjukdomshistorik. De med tidigare olyckor kostar 1,267 kr mer än de utan tidigare olyckor. Och för varje år, ökar en persons kostnad med 72 kr.

Även om modellen förklarar 68% av variationerna i kostnaden ville jag gå vidare och se om det fanns ytterligare variabler som kunde öka säkerheten i vår prognos.

model 2				
	Estimate	Std. Error	t value	Pr(>|t|)
(Intercept)	3,582	346.157	10.348	< 2e-16 ***
smokeryes	7,289	198.996	36.631	< 2e-16 ***
chronic_condition yes	4,092	181.249	22.579	< 2e-16 ***
age	71	6.274	11.257	< 2e-16 ***
prior_accidents	1,263	154.212	8.188	7.51e-16 ***
exercise_levellow	1,796	226.755	7.921	5.88e-15 ***
exercise_levelmedium	806	203.546	3.958	8.04e-05 ***
sexmale	-201	153.221	-1.313	0.189
annual_checkups	-3	67.33	-0.048	0.962
Residual standard error: 2511 on 1069 degrees of freedom				
Multiple R-squared: 0.7029				
Adjusted R-squared: 0.7007				
F-statistic: 316.2 on 8 and 1069 DF, p-value: < 2.2e-16				

I modell 2 inkluderade jag därför även träningsnivå, kön och hälsokontroller. Notera att när R hanterar kategoriska variabler i regression så utelämnas en kategori som referenskategori. Så koden

```
model_2 <- lm(charges ~ smoker + chronic_condition + age + prior_accidents +
                exercise_level + sex + annual_checkups,
              data = insurance_clean)
```

ger två utav de tre träningsnivåer i vår output, vilket tolkas som
exercise_levellow: låg träning kostar 1 810 kr mer än hög träning
exercise_levelmedium: medel träning kostar 816 kr mer än hög träning

Modell 2 förklarar 70% av variationerna i kostnader. Bättre än modell 1 men kön och hälsokontroller verkar ha liten eller ingen påverkan (litet statistiskt stöd) med p-värden på 0.2 och 1.0 respektive.

Därefter gick jag vidare med en tredje modell, som var samma som modell 1 men med träningsnivå som en ytterligare variabel.

model 3				
	Estimate	Std. Error	t value	Pr(>|t|)
(Intercept)	3,479	313.286	11.105	< 2e-16 ***
smokeryes	7,288	198.96	36.631	< 2e-16 ***
chronic_conditionyes	4,088	179.988	22.714	< 2e-16 ***
age	70	6.268	11.224	< 2e-16 ***
prior_accidents	1,262	154.176	8.187	7.55e-16 ***
exercise_levellow	1,810	226.489	7.99	3.47e-15 ***
exercise_levelmedium	816	203.378	4.011	6.47e-05 ***
Residual standard error: 2511 on 1071 degrees of freedom				
Multiple R-squared: 0.7024,				
Adjusted R-squared: 0.7008				
F-statistic: 421.4 on 6 and 1071 DF, p-value: < 2.2e-16				

Det visade sig att modell 3 också förklarade 70% av variationerna i kostnaden, samma som modell 2, men med färre variabler, vilket fick mig att känna att det var ett bättre modellval. Man vill inte komplicera regressionsmodellen mer än nödvändigt, och färre variabler är i detta fall precis lika bra som fler. Alla variablerna i modell 3 har p-värden under 0.05, vilket innebär att vi med god säkerhet kan säga att de har ett verkligt samband med kostnader.

Modelljämförelse			
model	r_squared	adjusted_r_squared	residual_se
Model 1: rökning + kronisk + ålder + olyckor	0.684	0.683	2585
Model 2: + träning + kön + hälsokontroller	0.703	0.701	2511
Model 3: + träning (utan kön och hälsokontroller)	0.702	0.701	2511

Därför fortsätter jag med **modell 3** och utvärderar den vidare.

När jag plottar residualer mot predikterat värde, kan jag se att modell 3s predikerade värden verkar vara jämnt fördelat på båda sidor om vår noll-linje, även om det finns outliers. Men plotten indikerar i alla fall inte att det finns någon bekymmersam snedfördelning.

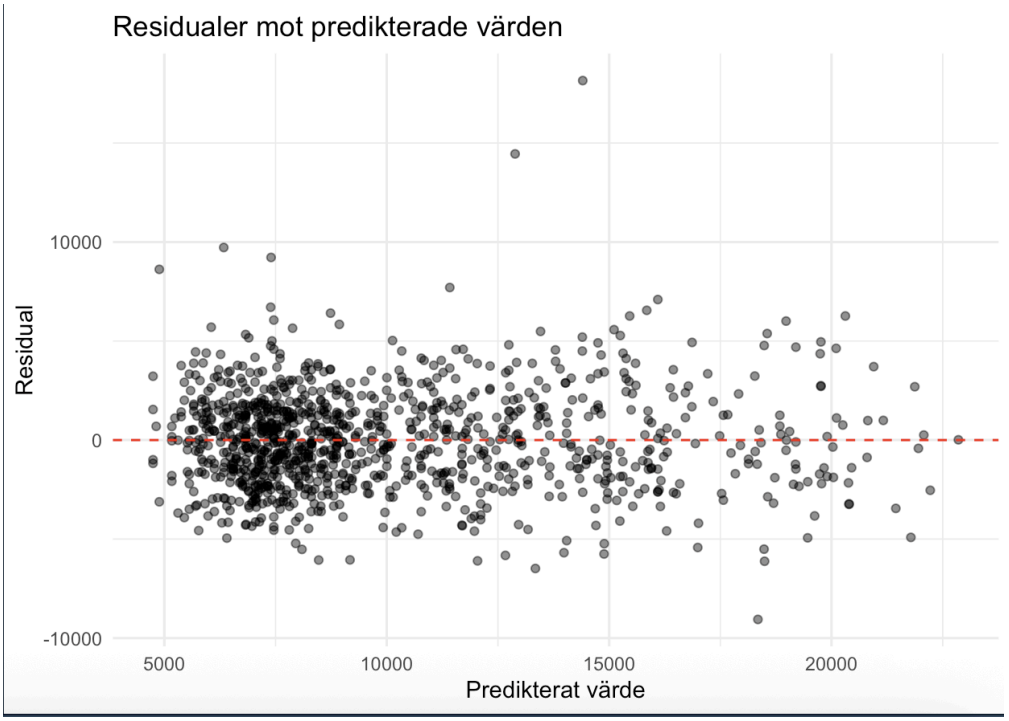

När man tittar på faktisk kostnad mot predikterad kostnad, ser man samma outliers för högre faktisk kostnad som jag har identifierat tidigare. Detta är inte konstigt i försäkringsdata då det kommer att finnas försäkringstagare vars försäkringshändelser kommer att resultera i ovanligt höga kostnader som inte kan förutspås. Trendlinjen visar dock visuellt vad vi har sett i vår modellanalys - att modellen ändå fångar upp en majoritet av variationerna i datan.

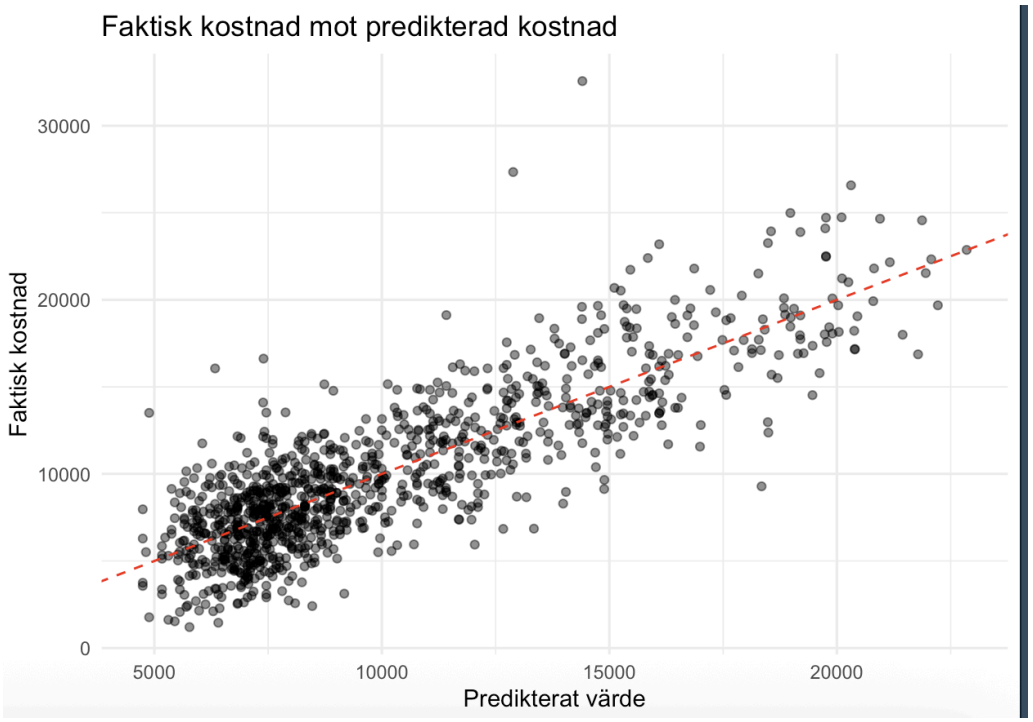

Jag gick vidare med att titta på en quantile-quantile plot för residualerna. Här ser man att punkterna ligger rätt tätt på den röda linjen som indikerar normalfördelning, fram till de högre värdena då ‘svansen’ av datan avviker. Som vi har sett tidigare kan modellen hantera större

delen av datan men klarar inte av de mer extrema fallen, men modellen är fortfarande användbar. Avvikelserna i Q-Q plotten är alltså inte tillräckliga för att jag ska förkasta modell 3.

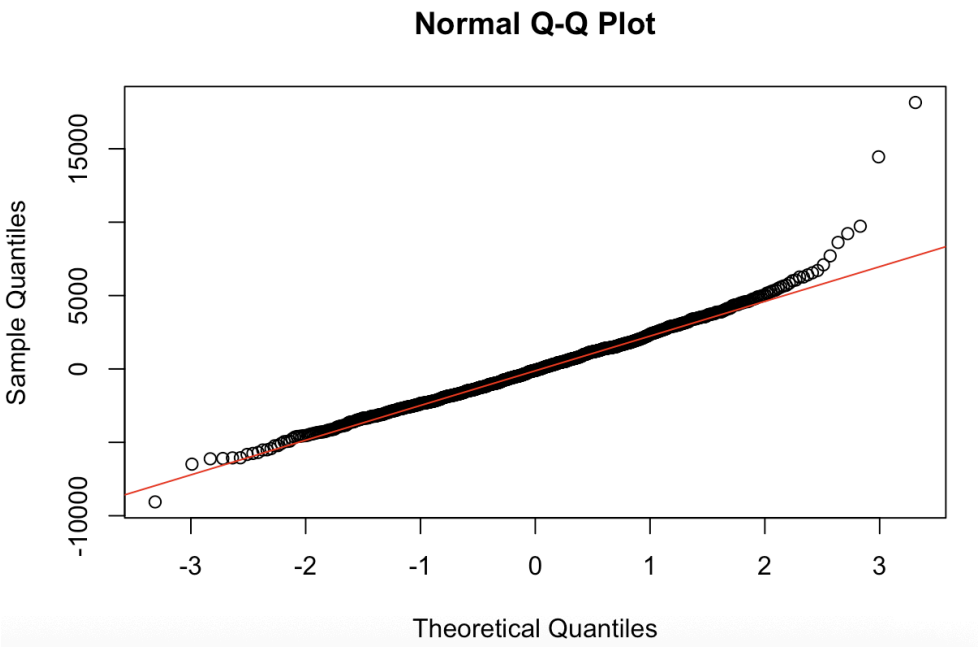

För att illustrera modellens användbarhet testades fyra hypotetiska kundprofiler, alla 45 år gamla:

Person 1 (rökare, kronisk sjukdom, 45 år, 1 olycka, låg träning)	21 093 kr
Person 2 (icke-rökare, ingen kronisk sjukdom, 45 år, 0 olyckor, hög träning)	6 645 kr
Person 3 (icke-rökare, kronisk sjukdom, 45 år, 0 olyckor, låg träning)	12 543 kr
Person 4 (rökare, ingen kronisk sjukdom, 45 år, 0 olyckor, hög träning)	13 933 kr

Skillnaden mellan lägsta och högsta riskprofil uppgår till över 14 000 kr för samma ålder, vilket visar att modellen fångar meningsfulla skillnader mellan kundgrupper.

Slutligen undersökte jag modellens predikade kostnader mot kundernas försäkringsplaner:

Genomsnittskostnad per plannivå				
plan_type	antal	medel_faktisk	medel_förutsagd	differens
basic	334	9,061	9,675	-614
premium	200	11,273	10,445	827
standard	544	10,218	10,145	73

Här kunde jag utläsa att Basic-kunderna i genomsnitt kostar mindre än förväntat medan Premium-kunder i genomsnitt kostar mer än prognostiserat av modellen. Kostnader för Standard-kunder var som förväntat enligt modellen. Jag vet dock inte hur mycket varje kund

faktiskt betalar, även om man kan förmoda att Basic-kunder betalar mindre än Standard- och Premium-kunder och antagligen har sämre försäkringsskydd.

Slutsatser

Jag kan se tydliga korrelationer mellan målvariabeln kostnader, och variablerna rökning, sjukdomshistorik, ålder, tidigare olyckor och träningsnivå.

När jag jämför modellens kostnadsprediktion mot försäkringsbolagets prisplan verkar prisplanstrappan vara rimlig men att det kan finnas skäl att se över prissättningen för premium-planen, där modellen förutspår lägre kostnader än verkligt utfall. Men jag måste samtidigt vara medvetna om att det finns outliers i data och att 30% av variationerna i datan inte kan förklaras av vår modell.

Givet de förklarande variabler jag har analyserat, skulle försäkringsbolaget kunna använda försäkringspremie-rabatter som incitament för kunder som inte röker och som tränar regelbundet, eftersom de livsstilsfaktorerna drar ned försäkringskostnaderna. Vad det gäller korrelation kring kostnader och ålder, olyckor och kronisk sjukdom, så är det möjligt att premien kommer att öka med försäkringstagarens ålder, antal tidigare olyckor och sjukdomshistoria.

Begränsningar

Jag har valt att bara titta på ett urval av variablerna som fanns tillgängliga i datasetet, ett urval som skedde rent intuitivt. För att fånga upp ytterligare variabler som påverkar kostnaderna och träna upp en modell som fångar mer än 70% av variationerna skulle jag behöva utvärdera alla tillgängliga variabler.

Man ska också vara medvetna om att en linjär regressionsmodell, även om den använder multipla variabler, är en enkel modell som endast tittar på linjära samband. Jag skulle kunna ha förbättrat vårt tillvägagångssätt genom att använda datan för maskininlärning, som till exempel Random Forest eller Gradient Boosting, som till skillnad från linjär regression kan fånga upp icke-linjära samband och mer komplexitet mellan variabler. Dessa modeller tränas på en del av datan och utvärderas sedan på en separat testdel. Ett sådant tillvägagångssätt hade potentiellt kunnat förklara en större del av variationen i försäkringskostnaden.

Självreflektion

Jag tyckte att jag gjorde ett bra jobb i analysen, där jag testade olika variabler både de i rådatan, och som jag hade skapat själv. Jag höll inte fast vid variabler som jag trodde skulle vara relevanta (så som min egen åldersgruppering till exempel) utan tog mig an uppgiften med ett öppet sinne och nyfikenhet. Dock tittade jag inte på alla tillgängliga variabler, vilket helt klart är en begränsning.

Det svåraste var att analysera modellutvärderingen. Här hade jag hjälp av lektionsviderona men det kräver kunskap att förstå vad figurer och statiska variabler visar. Det näst svåraste var att få till en .qmd rapport som såg snygg ut i htlm. Jag började men kände att det tog för lång tid och jag gick tillbaka till en simpelt word format istället. Det var en besvikelse.

Jag tror att jag borde hamna på VG för den här inlämningsuppgiften, då jag har tittat på flera modellvarianter och resonerat kring dem.